## PROCESSAMENTO DE LINGUAGEM NATURAL


**Redes Neurais Profundas** 

## TÓPICOS

- 1. Introdução
- 2. Camadas de convolução e pooling
- 3. CNN para classificação de textos

#### **REDES NEURAIS**


Camadas totalmente conectadas (Fully-Connected Layers)



**1 número: o** resultado do produto interno entre uma linha de W e a entrada (um produto interno de 3072 dimensões)

**Problema**: os classificadores não respeitam a estrutura espacial de imagens.


**Solução**: definir novos nós computacionais que operem em imagens.



## O QUE É RN CONVOLUCIONAL?

- "Rede Neural feed-forward cujos neurônios estão dispostos de tal forma a responder por regiões sobrepostas (campos receptores) que preenchem o campo visual"
- "Múltiplas camadas de pequenas coleções de neurônios que processam porções da imagem de entrada (campos receptores)"
- "Sequências de camadas de convolução intercaladas por funções de ativação"

#### REDE NEURAL CONVOLUCIONAL



Começaremos com a camada de convolução

Imagem  $32 \times 32 \times 3$ 






Imagem  $32 \times 32 \times 3$ 




Filtro  $5 \times 5 \times 3$ 



Convoluir o filtro com a imagem


Deslizar espacialmente o filtro pela imagem, computando produtos internos

Imagem  $32 \times 32 \times 3 \leftarrow$ 



Filtros sempre compreendem a profundidade inteira do volume de entrada

Filtro  $5 \times 5 \times 3$ 



Convoluir o filtro com a imagem

Deslizar espacialmente o filtro pela imagem, computando produtos internos





Imagem  $(32 \times 32 \times 3)$ 

Filtro  $w(5 \times 5 \times 3)$ 

#### 1 número:

resultado do produto interno entre o filtro e uma porção  $5 \times 5 \times 3$  da imagem  $(5 \times 5 \times 3 = 75 \text{ parâmetros} + \text{bias})$ 





 $\text{Imagem}\ (32\times32\times3)$ 

Filtro  $w(5 \times 5 \times 3)$ 

convoluir (deslizar) sobre todas as regiões espaciais

# mapa de ativação







 $lmagem~(32\times32\times3)$ 

Filtro  $w_2(5 \times 5 \times 3)$ 


convoluir (deslizar) sobre todas as regiões espaciais mapa de ativação



considere a existência de um segundo filtro (amarelo)




Se tivermos 6 filtros  $5 \times 5 \times 3$ , teremos 6 featuremaps distintos:



Camada de Convolução


#### mapas de ativação



Empilhamos o *featuremaps* para gerar uma "nova imagem" de tamanho  $28 \times 28 \times 6$ 

#### REDE CONVOLUCIONAL

"Sequência de camadas de convolução intercaladas por funções de ativação"




# FUNÇÕES DE ATIVAÇÃO


## Sigmoid A



## Tanh 🔼








Interpretação da saída por taxa média de disparo Tende a saturar. Mata os gradientes. Não é centrada em zero. Custosa. Ruim para redes profundas

Centrada em zero. Mata os gradientes. Ruim para redes profundas.

> Leaky ReLU **PReLU** ELU

#### ReLU



Evita saturação. Boa para redes profundas. Convergência rápida. Eficiente.


Não centrada em zero.

#### CAMADA DE POOLING

- Reduz os volumes para que se tornem gerenciáveis
- Atua sobre cada mapa de ativação de maneira independente



#### REDE NEURAL CONVOLUCIONAL




Finalmente: FC (Fully-Connected Layer)

Uma rede convolucional pode conter uma ou várias camadas totalmente conectadas, e nelas os neurônios estão conectados com toda a entrada (redes neurais tradicionais).


#### TEXTO COM CNN


 Embora originalmente concebidas para processamento de imagens, CNNs também são frequentemente utilizadas para processamento de texto...


Imagem do paper "Very Deep Convolutional Networks for Text Classification" de Conneau et al., EACL 2017





















































































t = 8 + 2 (pad)









t = 8 + 2 (pad)







t = 8 + 2 (pad)








t = 8 + 2 (pad)

3 filtros de tamanho  $3 \times d$ 





3 filtros de tamanho  $3 \times d$ 




Volume de Saída



- d = 4
- 1 camada de Conv1D com filtro de tamanho 3 aprende relações entre 3 palavras vizinhas (trigramas)
- t = 8 + 2 (pad)
- O que fazer para aprender relações entre mais palavras?







#### Volume de Saída



- Aumentar o tamanho do filtro (features mais globais), porém, com aumento do número de parâmetros....
- t=8+2 (pad) Aumentar o campo receptor via mais camadas (mais flexibilidade com menos parâmetros)

# CNN: CLASSIFICAÇÃO DE TEXTOS

- 1. Word Embeddings + CNN
- 2. Usar uma CNN com uma única camada
- 3. Hiperparâmetros das CNNs
- 4. CNNs em nível de caractere
- 5. CNNs profundas

https://machinelearningmastery.com/best-practices-document-classification-deep-learning/

# O QUE VIMOS?

- Introdução
- Camadas de convolução e pooling
- CNN para classificação de textos

# PRÓXIMA VIDEOAULA

Prática: Classificação de Textos